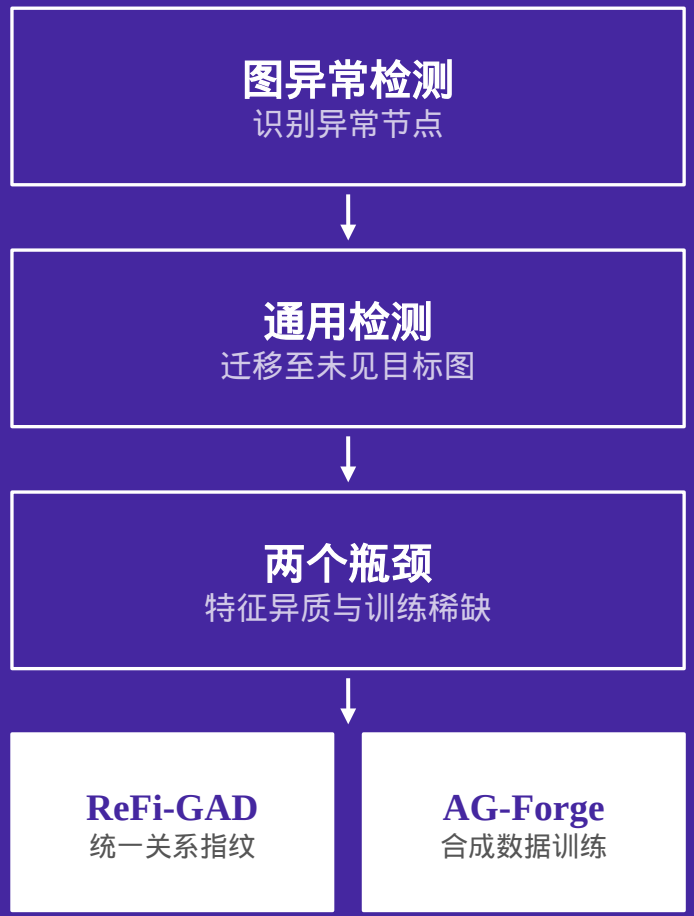
方向概览



GeneralistGAD

通用图异常检测：从特征对齐到合成数据

ReFi-GAD 与 AG-Forge 论文精读

Relational Fingerprints for Cross-graph Transfer

Synthetic Graphs with Topology-Semantic Coordination

汇 报 人：[汇报人姓名]

汇报时长：20–30 分钟

汇报日期：2026 年 10 月 23 日

目 录 CONTENTS

- ☐ **研究背景** *Generalist GAD*
- ☐ **ReFi-GAD ：关系指纹对齐** *ICML 2026*
  - ◣ 动机：预训练为何失效 *Motivation*
  - ◣ 方法：指纹与自适应编码 *Method*
  - ◣ 实验：收益与边界 *Experiments*
- ☐ **AG-Forge ：合成数据训练** *arXiv 2026*
  - ◣ 动机：训练数据稀缺 *Motivation*
  - ◣ 方法：生成器与双流模型 *Method*
  - ◣ 实验：替代性与增益来源 *Experiments*
- ☐ **对比与讨论** *Comparison & Discussion*
- ☐ **未来方向** *Future Directions*

目 录 CONTENTS

☐ 研究背景 *Generalist GAD*

☐ ReFi-GAD ：关系指纹对齐 *ICML 2026*

☐ AG-Forge ：合成数据训练 *arXiv 2026*

☐ 对比与讨论 *Comparison & Discussion*

☐ 未来方向 *Future Directions*

问题设定：训练一次，迁移到未见图

问题背景

- 通用 GAD 在源图学习，目标图上**不更新模型参数**
- 本次两种方法都利用目标图中的**带标签支撑节点**

传统图异常检测

- 通常在目标图上训练并检测，换图后需要重新训练。

本次精读的通用设定

- 训练源图与测试目标图分离，支撑集提供正常和异常样本作参照。
- “测试时免训练”仍需目标图的特征与结构，也需要少量标签。

共同评测口径

- 在 14 个真实图上报告 AUROC / AUPRC ，跨目标图共用超参数。

来源： ReFi-GAD ， arXiv:2605.25429v1 ， §3 、 §5.1 ；来源： AG-Forge / TS-GGAD ， arXiv:2610.12167v1 ， §2 、 §4.1

两篇论文分别改进通用 GAD 的哪一环

研究主线

- 先解决**输入可迁移**，再探索**训练数据可扩展**

环节	既有做法 / 现象	论文切入点
输入对齐	PCA / SVD 统一特征维度，语义仍可能错位	ReFi-GAD ：用关系统计量构建统一输入
检测模型	ARC 、 UNPrompt 、 IA-GGAD 等引入跨图先验	利用支撑集提供目标图上下文
训练数据	既有模型仅用 1–7 个真实图，平均约 9 万节点	AG-Forge ：可组合、难度可控的异常图生成
规模利用	更多合成数据未让既有模型显著变强	TS-GGAD ：双流表达与课程学习

统一输入为跨域学习提供基础，扩展数据还需要模型与训练策略配合。

来源： ReFi-GAD ， arXiv:2605.25429v1 ，引言与相关工作；来源： AG-Forge / TS-GGAD ， arXiv:2610.12167v1 ，引言

目 录 CONTENTS

- ☐ 研究背景 *Generalist GAD*
- ☐ ReFi-GAD ：关系指纹对齐 *ICML 2026*
  - ◣ 动机：预训练为何失效 *Motivation*
  - ◣ 方法：指纹与自适应编码 *Method*
  - ◣ 实验：收益与边界 *Experiments*
- ☐ AG-Forge ：合成数据训练 *arXiv 2026*
- ☐ 对比与讨论 *Comparison & Discussion*
- ☐ 未来方向 *Future Directions*

目 录 CONTENTS

- ☐ **研究背景** *Generalist GAD*
- ☐ **ReFi-GAD ：关系指纹对齐** ***ICML 2026***
  - ◣ **动机：预训练为何失效** ***Motivation***
  - ◣ 方法：指纹与自适应编码 *Method*
  - ◣ 实验：收益与边界 *Experiments*
- ☐ **AG-Forge ：合成数据训练** *arXiv 2026*
- ☐ **对比与讨论** *Comparison & Discussion*
- ☐ **未来方向** *Future Directions*

动机一：源图预训练常常产生负迁移

问题描述

- 既有方法在 **7–9 个目标图**上出现负迁移
- ReFi-GAD 在 **12 个目标图**上获得正迁移

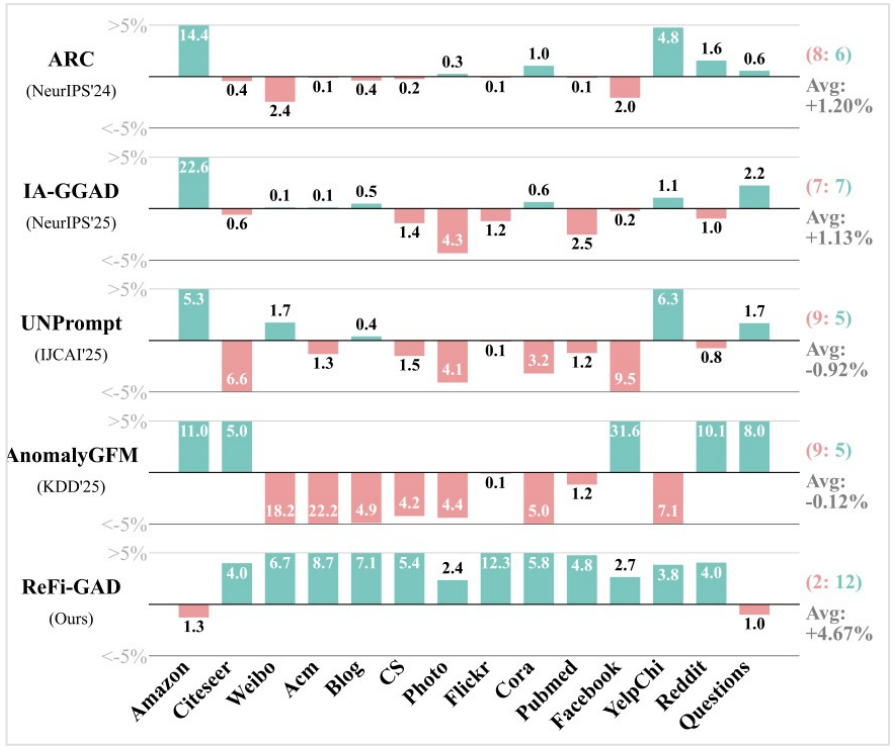


Fig. 1 ：预训练相对免训练版本的增益，括号为负迁移数与正迁移数

- **平均收益并不稳定**
  - ARC 与 IA-GGAD 略有正增益，另两种方法的平均值为负。
- **ReFi-GAD 平均增益为 +4.67**
  - 这是图中报告的 AUROC 增益，不能与跨方法差距混用。
- **需要区分架构先验与训练收益**
  - 免训练版本是检验预训练贡献的重要参照。

来源： ReFi-GAD ， arXiv:2605.25429v1 ， Fig. 1

动机二：维度一致，语义仍可能错位

核心洞察

- PCA 对齐后，特征仍明显**按数据集聚类**
- 免训练模型的表现依赖**邻域一致性先验**

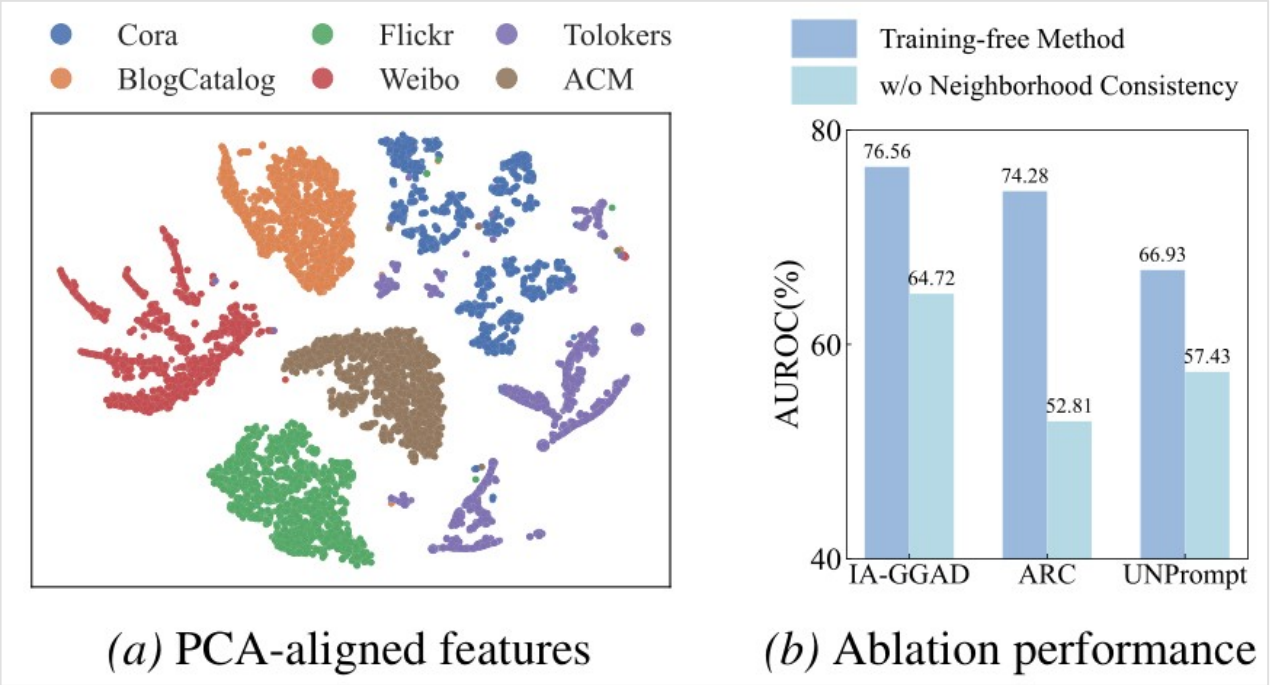


Fig. 2 ： PCA 特征的 t-SNE ，以及移除邻域一致性模块的消融

原始属性的含义不同

- 如词袋特征与用户统计量，投影后仍保留分布差异。

移除邻域一致性，性能下降

- 三种模型的平均 AUROC 均降低，说明关系线索有价值。

从数值对齐转向关系对齐

- 用节点与邻域、全局背景的关系描述异常。

目 录 CONTENTS

- ☐ **研究背景** *Generalist GAD*
- ☐ **ReFi-GAD ：关系指纹对齐** ***ICML 2026***
  - ◣ 动机：预训练为何失效 *Motivation*
  - ◣ **方法：指纹与自适应编码** ***Method***
  - ◣ 实验：收益与边界 *Experiments*
- ☐ **AG-Forge ：合成数据训练** *arXiv 2026*
- ☐ **对比与讨论** *Comparison & Discussion*
- ☐ **未来方向** *Future Directions*

ReFi-GAD ：先提取关系，再学习跨域模式

核心思想

- 以**五维关系指纹**替代异质原始输入
- 共享编码后，再按目标图上下文做 **SNR 自适应细化**

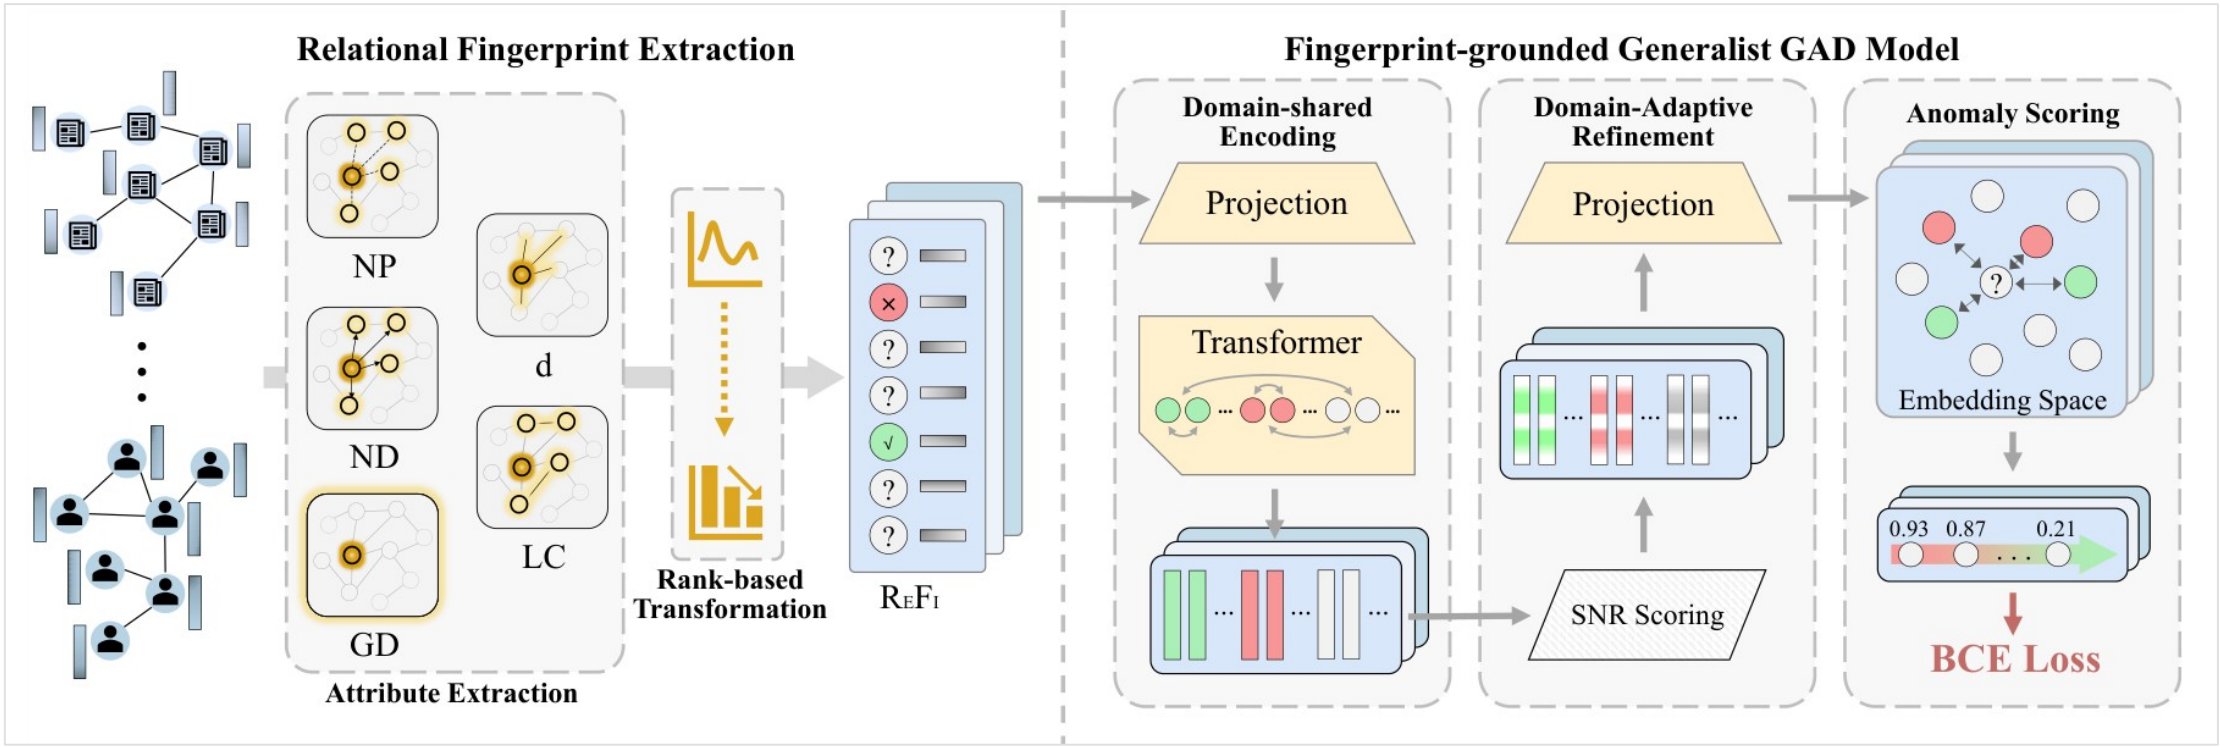


Fig. 3 ：关系指纹提取、域共享编码、域自适应细化与异常打分

关系指纹：五个维度各自提供什么信息

核心原理

- 所有图共享**同一组关系语义**，逐维排名统一尺度

维度	计算直觉	异常线索
NP 邻域位置一致性	相似度加权图卷积后，与邻居的平均欧氏距离	偏离局部社区
ND 邻域方向一致性	同一表示上，与邻居的平均余弦相似度	局部语义不一致
GD 全局方向一致性	两阶图卷积后，与全局均值方向比较	偏离全局背景
d 节点度	节点的连接数量	连接异常高或低
LC 局部聚类系数	邻居之间形成三角形的紧密程度	局部社区组织异常
统一处理： $r(m) = rank(m) / n$ ，将绝对数值转为图内相对位置		

指纹保留可跨图解释的异常关系，但人工选定的统计量也限制了可表达的信息。

来源： ReFi-GAD ， arXiv:2605.25429v1 ， §4.1 ， Eq. 1–7

共享编码与目标图细化如何协作

模型结构

- Transformer 学习**指纹间的组合关系**
- SNR 依据当前目标图，强调**更有区分度的维度**

带掩码的上下文编码

- MLP 投影后进入 Transformer ，查询节点只关注支撑节点和自身。
- 支撑节点之间相互可见，不读取查询节点。

逐维 SNR 加权

- $s = (h_a - h_n)^2 / (\sigma_n^2 + \varepsilon)$ ，再由 sigmoid 生成维度权重。
- 异常中心用异常支撑集估计，正常背景同时纳入正常支撑集与查询集。

打分与训练

- 比较查询与异常 / 正常支撑节点的余弦相似性，在源图上用 BCE 训练。

来源：ReFi-GAD ， arXiv:2605.25429v1 ， §4.2 ， Eq. 8–16

目 录 CONTENTS

- ☐ **研究背景** *Generalist GAD*
- ☐ **ReFi-GAD ：关系指纹对齐** ***ICML 2026***
  - ◣ 动机：预训练为何失效 *Motivation*
  - ◣ 方法：指纹与自适应编码 *Method*
  - ◣ **实验：收益与边界** ***Experiments***
- ☐ **AG-Forge ：合成数据训练** *arXiv 2026*
- ☐ **对比与讨论** *Comparison & Discussion*
- ☐ **未来方向** *Future Directions*

主结果：提升主要体现在较难的迁移组

实验结果

- ReFi-GAD 在 **13 / 14 个图**上获得最高 AUROC
- 逐集均值核算后，比 IA-GGAD 高 **7.40 个百分点**

方法	Group 1 均值	Group 2 均值	全部均值	平均排名
SmoothGNN	71.66	67.37	69.52	5.43
ARC	81.25	69.71	75.48	3.50
AnomalyGFM	44.67	52.27	48.47	12.21
UNPrompt	67.19	64.83	66.01	5.93
IA-GGAD	84.93	70.44	77.69	2.86
ReFi-GAD	**86.76**	**83.41**	**85.08**	**1.14**

收益随目标域变化，Amazon 上 ReFi-GAD 为 71.21，低于 IA-GGAD 的 82.49。

来源：ReFi-GAD，arXiv:2605.25429v1，Table 1；均值与差值由逐集值计算

消融：关系指纹贡献大于 SNR 细化

消融分析

- 替换指纹造成大幅下降， SNR 在其上提供**增量收益**

模型变体	全部 14 集均值	Group 2 均值	设计变化
w/o R&D	65.23	59.58	PCA ，移除细化
w/o R	64.69	59.31	PCA ，保留细化
w/o D	84.38	82.53	保留指纹，移除细化
ReFi-GAD	**85.08**	**83.41**	**完整模型**

20.39 与 24.10 对应不同统计范围：全部数据集与 Group 2 ，不能据此判定数值矛盾。

来源： ReFi-GAD ， arXiv:2605.25429v1 ， Table 2 、 Table 8 ；均值和差值经计算

目 录 CONTENTS

- ☐ 研究背景 *Generalist GAD*
- ☐ ReFi-GAD ：关系指纹对齐 *ICML 2026*
- ☐ AG-Forge ：合成数据训练 *arXiv 2026*
  - ◣ 动机：训练数据稀缺 *Motivation*
  - ◣ 方法：生成器与双流模型 *Method*
  - ◣ 实验：替代性与增益来源 *Experiments*
- ☐ 对比与讨论 *Comparison & Discussion*
- ☐ 未来方向 *Future Directions*

目 录 CONTENTS

- ☐ **研究背景** *Generalist GAD*
- ☐ **ReFi-GAD ：关系指纹对齐** *ICML 2026*
- ☐ **AG-Forge ：合成数据训练** ***arXiv 2026***
  - ◣ **动机：训练数据稀缺** ***Motivation***
  - ◣ 方法：生成器与双流模型 *Method*
  - ◣ 实验：替代性与增益来源 *Experiments*
- ☐ **对比与讨论** *Comparison & Discussion*
- ☐ **未来方向** *Future Directions*

数据放大后，模型与训练方式成为新瓶颈

问题描述

- 既有模型换成**合成图**训练，平均效果接近真实图训练
- TS-GGAD 进一步提升，说明还需改善**模型与训练方式**

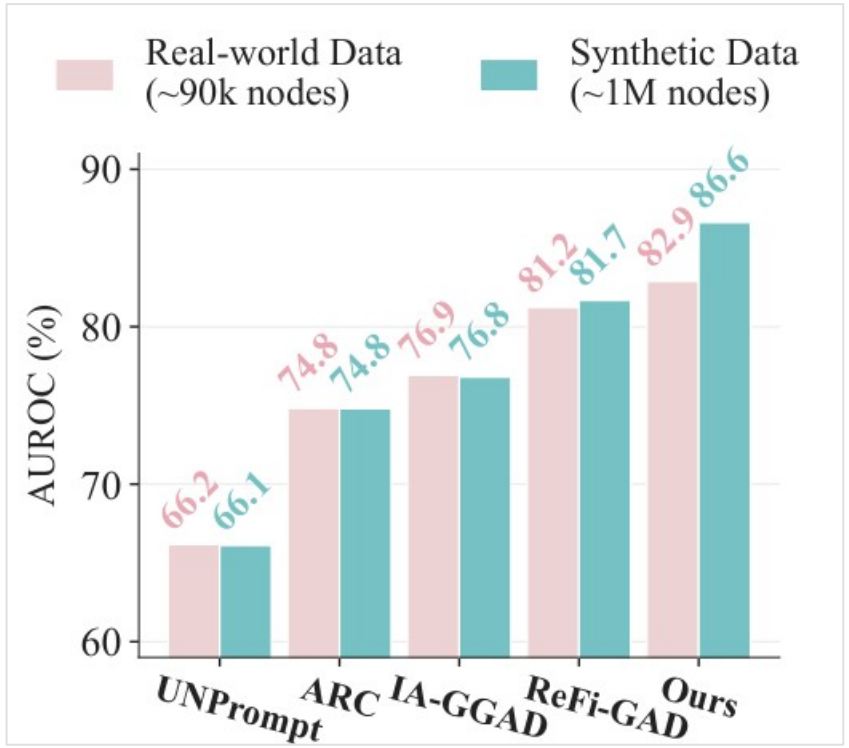


Fig. 1 ：真实源图约 9 万节点，合成图约 100 万节点

- **稀缺来自采集与标注成本**
  - 异常少见，真实图还受隐私和访问条件限制。
- **合成数据需要兼顾多样性**
  - 图结构、属性分布与异常模式相互耦合。
- **数量并不自动转化为收益**
  - 数据生成、双流模型和课程学习需要联合评估。

来源： AG-Forge / TS-GGAD ， arXiv:2610.12167v1 ，引言、 Fig. 1

目 录 CONTENTS

- ☐ **研究背景** *Generalist GAD*
- ☐ **ReFi-GAD ：关系指纹对齐** *ICML 2026*
- ☐ **AG-Forge ：合成数据训练** ***arXiv 2026***
  - ◣ 动机：训练数据稀缺 *Motivation*
  - ◣ **方法：生成器与双流模型** ***Method***
  - ◣ 实验：替代性与增益来源 *Experiments*
- ☐ **对比与讨论** *Comparison & Discussion*
- ☐ **未来方向** *Future Directions*

AG-Forge 造数据，TS-GGAD 学异常证据

核心思想

- 生成器控制**图结构、属性、异常和难度**
- 双流模型结合**课程学习**利用合成训练集

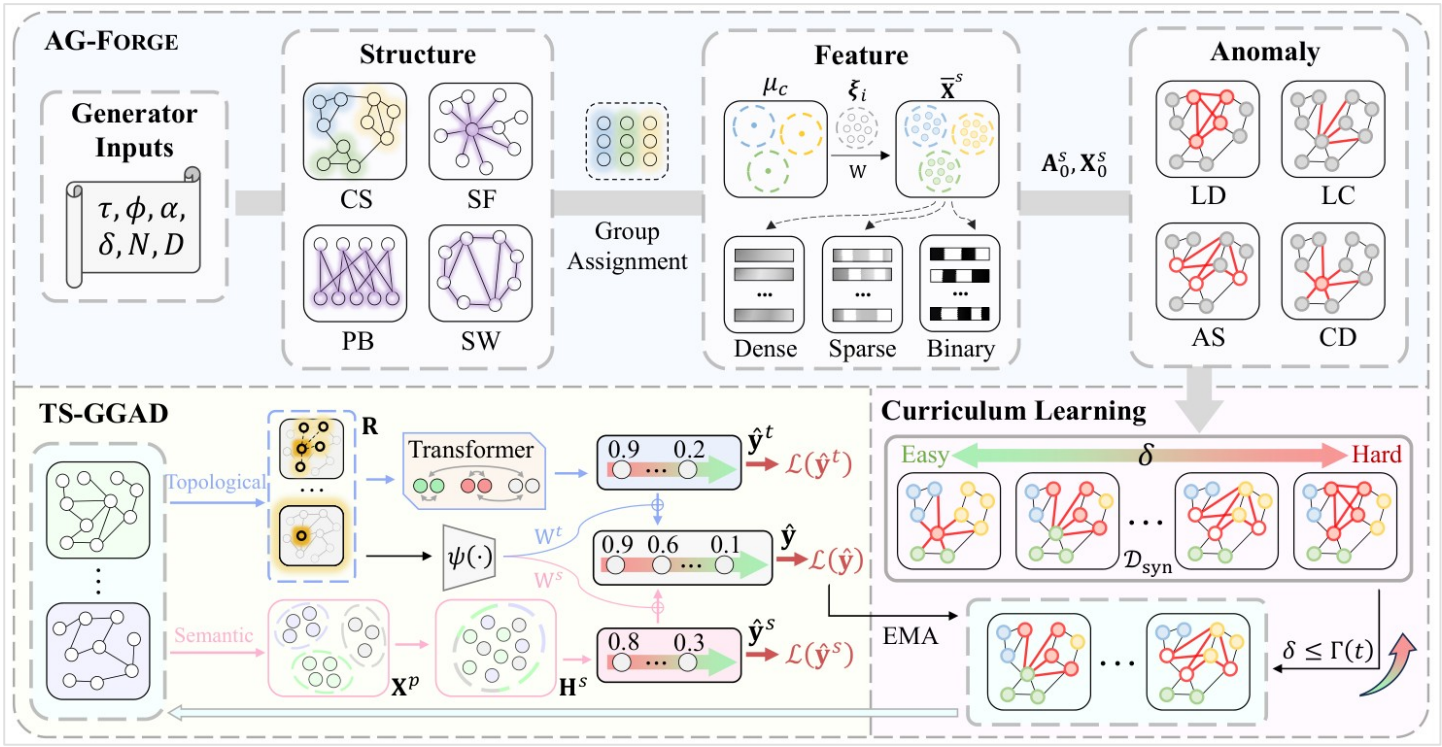


Fig. 2 ：上方为数据生成，下方为双流检测与课程学习

合成流水线：覆盖不同环境与异常模式

数据合成

- 各阶段可组合，并用 **δ 控制异常难度**

阶段	可选机制	如何产生多样性
结构生成	CS 社区、 SF 无标度、 PB 投影二部、 SW 小世界	改变社区关系、枢纽结构、共享邻居与长程连接
属性生成	Dense 稠密、 Sparse 稀疏、 Binary 二值	社区潜在中心叠加节点扰动，再随机投影与类型转换
异常注入	LD 局部稠密、 LC 链接集中、 AS 属性抑制、 CD 社区分散、 Mix 混合	改变连接与属性，并通过扰动强度和伪装程度调节难度

δ 越大通常越难检出，它既控制合成异常，也为课程学习提供初始难度顺序。

来源： AG-Forge / TS-GGAD ， arXiv:2610.12167v1 ， §3.1 ， Eq. 1–4

TS-GGAD ：互补证据与由易到难的学习

模型训练

- 拓扑关系与原始属性提供**互补异常证据**
- 图级与节点级难度共同影响**训练重点**

拓扑流与语义流

- 五维关系统计量配 Transformer ，另一路用 PCA 、地标散射归一化和 MLP 。

节点级证据融合

- 各分支比较正常与异常支撑节点的相似度，以关系描述预测两路门控权重。

课程学习

- 按 δ 逐步放入难图，再依据异常损失的 EMA 提高难图采样概率。
- 节点级 focal loss 强调难样本，融合结果与两个分支分别接受监督。

来源： AG-Forge / TS-GGAD ， arXiv:2610.12167v1 ， §3.2–3.3 ， Eq. 5–13

目 录 CONTENTS

- ☐ **研究背景** *Generalist GAD*
- ☐ **ReFi-GAD ：关系指纹对齐** *ICML 2026*
- ☐ **AG-Forge ：合成数据训练** ***arXiv 2026***
  - ◣ 动机：训练数据稀缺 *Motivation*
  - ◣ 方法：生成器与双流模型 *Method*
  - ◣ **实验：替代性与增益来源** ***Experiments***
- ☐ **对比与讨论** *Comparison & Discussion*
- ☐ **未来方向** *Future Directions*

主结果：纯合成训练可行，但收益依赖学习方式

实验结果

- 纯合成训练的 TS-GGAD 在**全部 14 个图**上排名第一
- 比真实训练 ReFi 高 **5.39** ，比合成训练 ReFi 高 **5.03** 个百分点

方法	真实源图训练	合成图训练	均值变化
ARC	74.82	74.79	-0.03
UNPrompt	66.17	66.11	-0.06
IA-GGAD	76.92	76.79	-0.13
ReFi-GAD	81.22	81.59	+0.37
TS-GGAD	**82.9（ Fig. 1 ）**	**86.61**	**约 +3.7**

合成图对旧模型的平均影响很小，额外收益来自数据、模型和训练策略的共同变化。

来源： AG-Forge / TS-GGAD ， arXiv:2610.12167v1 ， Table 1 逐集均值计算；真实 TS 仅见 Fig. 1

消融：关系流是基础，语义与课程仍有贡献

消融分析

- 移除拓扑流损失最大，课程学习与语义流**也均有贡献**

消融对象	变体	平均 AUROC	相对完整模型
TS-GGAD	移除拓扑流	66.13	−20.48
	移除课程学习	81.18	−5.43
	移除语义流	82.03	−4.58
	以简单融合替代门控	85.64	−0.97
生成策略	去掉一种结构机制	83.07–85.22	平均 − 2.33
	去掉一种属性机制	84.29–85.57	平均 − 1.80
	去掉一种异常机制	85.33–85.66	平均 − 1.07

拓扑关系仍是主要信号，语义分支与训练课程补足了仅靠关系统计量的不足。

来源： AG-Forge / TS-GGAD ， arXiv:2610.12167v1 ， Fig. 3–4 、 Table 6–7 ；完整均值 86.61

目 录 CONTENTS

☐ 研究背景 *Generalist GAD*

☐ ReFi-GAD ：关系指纹对齐 *ICML 2026*

☐ AG-Forge ：合成数据训练 *arXiv 2026*

☐ 对比与讨论 ***Comparison & Discussion***

☐ 未来方向 *Future Directions*

两篇论文的关系：扩展同一条技术路线

横向对比

- 第二篇延续**关系指纹**，并补充属性证据与合成训练

维度	ReFi-GAD	AG-Forge + TS-GGAD
主要瓶颈	特征维度统一后，语义仍错位	真实异常图训练数据稀缺
方法增量	人工关系指纹与 SNR 细化	组合生成、双流证据与课程学习
训练来源	真实源图，两组交替训练	纯合成图，真实图用于测试
各自报告的均值	85.08 ，默认每类 k=50	86.61 ，默认支撑参数 K=30
作者自述局限	依赖上下文支撑样本，指纹需人工设计	缺少系统的合成数据质量评估

两篇原报均值的直接相减不构成受控比较，结论应优先建立在各自论文内部对照上。

来源： ReFi-GAD ， arXiv:2605.25429v1 ， §5.1 、 结论；来源： AG-Forge / TS-GGAD ， arXiv:2610.12167v1 ， §4.1 、 结论

值得讨论：证据能支持到哪一步

问题讨论

- **实验范围与统计口径**决定结论边界

同一基线跨论文存在差异

- ReFi-GAD 均值为 85.08 与 81.22 ，支撑设置不同，其他因素仍需受控复现。

“少量标签”是否构成实际部署成本

- 第一篇默认每类 50 个支撑节点，测试阶段仍需要异常标签。

合成覆盖的证据仍偏定性

- t-SNE 的重叠不能替代质量度量，应检查未知异常类型与跨域泛化。

容量解释需要进一步隔离变量

- 在相同参数量、训练预算和数据量下，分别验证语义流与课程学习。

来源：两篇论文设定与分析；讨论中的检验建议为汇报者提出

目 录 CONTENTS

☐ 研究背景 *Generalist GAD*

☐ ReFi-GAD ：关系指纹对齐 *ICML 2026*

☐ AG-Forge ：合成数据训练 *arXiv 2026*

☐ 对比与讨论 *Comparison & Discussion*

☐ 未来方向 ***Future Directions***

未来方向：从可迁移输入到可评估的训练数据

减少测试时对标签支撑的依赖 *Zero-shot Generalist GAD*

- 第一篇作者方向：探索无标签上下文的可靠异常打分。

学习关系指纹的选择与组合 *Learned Relational Fingerprints*

- 第一篇作者方向：降低人工设计依赖，并检验属性信息损失。

建立合成图质量与筛选标准 *Synthetic Data Evaluation*

- 第二篇作者方向：衡量多样性、真实性与下游迁移收益。

开展固定预算的规模实验 *Controlled Scaling*

- 汇报者建议：对齐支撑设置、参数量与算力，分离数据和模型的增益。

来源：ReFi-GAD，arXiv:2605.25429v1，结论；来源：AG-Forge / TS-GGAD，arXiv:2610.12167v1，结论；末项为汇报者建议

谢 谢 聆 听

Thank You & Questions ?

欢迎批评指正